

Mohamed Neuja Diop

Rapport d'Analyse Statistique : Étude du fichier "Salary_Data.csv"

Objectif du Projet

Ce projet a pour but d'analyser un jeu de données contenant des informations sur des employés (âge, genre, niveau d'éducation, poste, années d'expérience, salaire) afin d'en extraire :

- Des **mesures de tendance centrale** (moyenne, médiane, mode)
- Des **mesures de dispersion** (étendue, écart-type, variance, quartiles, coefficient de variation)

L'analyse s'appuie sur les bibliothèques Python suivantes :

- **Pandas** pour la manipulation de données
- **NumPy** pour les calculs statistiques
- **Matplotlib** et **Seaborn** pour les visualisations graphiques

1. Chargement des données :

Les colonnes du jeu de données sont :

- **Age** : Âge de l'employé
- **Gender** : Genre
- **Education Level** : Niveau d'éducation
- **Job Title** : Intitulé du poste
- **Years of Experience** : Années d'expérience
- **Salary** : Salaire annuel (€)

2. Valeurs manquantes :

Age	2
Gender	2
Education level	3
Jobs title	2
Years of experience	5

Comme on étudie sur deux variables seulement âge et salaire. On a remplacé les valeurs manquantes de salaire et âge par leurs moyennes.

3. Mesure de tendance centrale :

Mesure	Age	Salaire
Moyenne	34 ans	115326,96

Mediane	32 ans	115000
Mode	27 ans	140000

Interprétation :

- La moyenne donne une idée générale du niveau des salaires et des âges.
- La médiane est robuste face aux valeurs extrêmes (outliers).
- Le mode indique la valeur la plus fréquente dans l'échantillon.

4. Mesures de dispersion :

Mesure	Age	Salaire
Etendue	41 ans	249650
Ecart-type	7,61 ans	52786,18
Variance	57,98	2786381211,85
Coefficient de variation	22,65%	45,77%

Interprétation :

- L'écart-type et la variance montrent que les salaires sont beaucoup plus dispersés que les âges.
- Le coefficient de variation (CV) confirme cela : un CV de 45,77 % signifie une grande variabilité relative des salaires par rapport à leur moyenne.

5. Les quartiles :

Les **quartiles** permettent de diviser les données en quatre parties égales :

Quartiles de l'Âge :

- Q1 (25%) : 28 ans
- Q2 (50%, médiane) : 32 ans
- Q3 (75%) : 38 ans

Quartiles du Salaire :


- Q1 (25%) : 70 000 €
- Q2 (50%, médiane) : 115 000 €
- Q3 (75%) : 160 000 €

Interprétation :

- 25 % des employés ont un salaire inférieur à 70 000 €.
- 25 % des employés ont un salaire supérieur à 160 000 €.

6. Visualisation graphique :


1. Histogramme des salaires :



Interprétation

- L'histogramme montre la fréquence des salaires.
- La **moyenne (rouge)** est légèrement à droite de la **médiane (verte)**, ce qui indique une **légère asymétrie positive** (présence de salaires très élevés).
- Le **mode (orange)** est plus à droite : c'est la valeur la plus fréquente, souvent autour de 140 000 €.
- La courbe KDE (courbe de densité) donne une approximation douce de la distribution.

2. Histogramme des âges :




Interprétation

- **Répartition étendue** : les salaires varient entre environ **0 €** et **250 000 €**.
- La **médiane** est légèrement décalée vers la gauche, suggérant une **légère asymétrie à droite** (présence de salaires plus élevés mais

pas suffisamment extrêmes pour être considérés comme des outliers).

- **Pas d'outliers** malgré une forte dispersion → la distribution reste globalement régulière dans ses bornes.


3. Boxplot du salaire :



Interprétation

- Le **boxplot** affiche les quartiles (Q1, Q2, Q3) et l'étendue des salaires.
- Le **trait central** représente la **médiane** (115 000 €).
- Contrairement à ce que l'on pourrait attendre avec une telle dispersion, **aucune valeur extrême (outlier)** n'est visible dans ce boxplot.
- Cela signifie que **tous les salaires sont inclus dans l'intervalle interquartile élargi** (valeurs non considérées comme aberrantes selon la règle des $1.5 \times \text{IQR}$).


4. Boxplot de l'âge :



Interprétation

- La majorité des employés ont entre **28 et 38 ans**, ce qui indique une population assez **jeune et concentrée**.
- La présence de **valeurs aberrantes à droite** montre une **asymétrie positive** : quelques individus ont un âge significativement plus élevé que les autres.
- Il n'y a **pas d'outliers vers les âges très bas**, ce qui montre une coupure nette vers le bas (aucun très jeune employé).

5. Diagramme de dispersion entre âge et salaire :




Interprétation

- On observe une tendance générale selon laquelle **le salaire augmente avec l'âge**.

- Cela suggère que les personnes plus âgées tendent à avoir des salaires plus élevés, ce qui est cohérent avec l'idée que l'expérience accumulée se traduit souvent par une rémunération supérieure.
- Quelques points en bas du graphique indiquent des **salaires très bas**, même pour des personnes dans la quarantaine ou la cinquantaine.
- À l'inverse, on note quelques salaires **très élevés** vers **250 000 €**.

6. Régression linéaire :



- On voit une regression croissante.
- On constate que plus l'âge augmente, plus le salaire augmente.